




به نام خالق زیبایی‌ها

پروژه اول بوت‌کمپ جنگو دلتا | سری دوازدهم بوت‌کمپ‌های کوئرا
۱۴۰۵ بهار

تحلیل داده‌های زلزله در ژاپن

این پروژه با هدف جمع‌آوری، یکپارچه‌سازی و تحلیل داده‌های زلزله‌خیزی ژاپن انجام می‌شود. برای پیاده‌سازی این پروژه، از ترکیب چند ابزار استفاده می‌شود:

- **SQL** برای ذخیره‌سازی داده‌ها، پاک‌سازی، تبدیل، گروه‌بندی و انجام تحلیل‌های آماری
- **Pandas** برای خواندن فایل‌های CSV، انجام پیش‌پردازش اولیه و انتقال داده‌ها به پایگاه داده
- **Requests**، **BeautifulSoup** و **Selenium** برای استخراج داده‌ها از API و صفحات وب
- **Matplotlib** برای مصورسازی نتایج و نمایش الگوهای آماری

همچنین در صورت نیاز به محاسبات عددی تکمیلی، می‌توان از **NumPy** به صورت مکمل استفاده کرد.

توجه کنید که:

- در این پروژه نیاز به نگهداری داده‌ها در فایل‌ها و **دیتابیس** دارید.
- همچنین کد شما در همان محیط **ترمینال** اجرا می‌شود و نیاز به پیاده‌سازی رابط کاربری (UI) ندارید.
- استفاده از **گیت** در این پروژه **الزامیست**. شما می‌بایست از ابتدا با گیت کار کرده و ریپازیتوری پروژه خود را در گیت هاب بسازید. تمام تاریخچه فعالیت‌های شما در ریپازیتوری پروژه مشاهده می‌شود لذا نمی‌توانید صرفاً در آخر کار کدهای تکمیل‌شده را در گیت هاب قرار دهید. در انتها تنها لینک گیت هاب خود را داخل یک فایل متنی قرار دهید. (تنها فرمت قابل قبول همین است و بارگذاری فایل پایتون امکان‌پذیر نمی‌باشد)
- سعی کنید از یک ورژن مشخص پایتون و کتابخانه‌ها استفاده کنید و یک VENV مربوط به پروژه بسازید و کنار پروژه فایل requirements که شامل کتابخانه‌ها و ... را کنار فایل اصلی پروژه خود بسازید. همچنین یک فایل Readme در کنار پروژه می‌تواند دید بهتری به کد شما بدهد.
- برای شروع پروژه خود و دید بهتر نسبت به مسیر و تقسیم‌بندی بهتر وظایف استفاده از فلوچارت اجباری می‌باشد.
- در نهایت برای ارائه‌های خود یک فایل پاورپوینت ارائه آماده‌سازی کنید

در ادامه توضیحات پیاده‌سازی هر بخش برای شما آمده است.

۱. سناریوی رخداد زلزله

ژاپن همواره به‌عنوان یکی از زلزله‌خیزترین کشورهای جهان شناخته شده است. هدف این پروژه تحلیل جامع داده‌های زلزله یک‌ماهه گذشته در ژاپن است تا بتوانید از صفر تا تحلیل نهایی، داده‌های واقعی را از سه منبع معتبر (EMSC و USGS و GEOFON) و دیتاستی که برای شما از زلزله‌های ژاپن تهیه کردیم جمع‌آوری، پردازش، تحلیل آماری و بصری‌سازی کنید و نتایج را گزارش دهید. تمرکز اصلی بر درک تفاوت منابع، کیفیت داده‌ها، تحلیل خطر و استخراج اطلاعات مفید خواهد بود.

۲. استخراج و گردآوری داده‌ها

منبع اول دریافت داده‌های زلزله از API USGS: از سرویس Earthquake Catalog API سازمان زمین‌شناسی آمریکا (USGS) استفاده کنید تا داده‌های زلزله‌های ژاپن را در بازه زمانی ماه گذشته دریافت نمایید. می‌توانید پارامترهایی مانند محدوده جغرافیایی ، بازه زمانی و حداقل بزرگی را مشخص کنید و خروجی را به فرمت CSV ذخیره کنید.

```
import requests

from datetime import datetime, timedelta

end_date = datetime.today().date()

start_date = end_date - timedelta(days=30)

url = "https://earthquake.usgs.gov/fdsnws/event/1/query"

params = {

    "format": "csv",

    "starttime": str(start_date),

    "endtime": str(end_date),

    "minlatitude": 24,

    "maxlatitude": 46,

    "minlongitude": 123,

    "maxlongitude": 146,

    "minmagnitude": 1
```

```

}

response = requests.get(url, params=params)

with open("japan_earthquakes.csv", "w", encoding="utf-8") as f:
    f.write(response.text)

```

منبع دوم وباسکرپینگ از GEOFON: از وبسایت موسسه GFZ Helmholtz Centre for Geosciences، جدول زلزله‌های ژاپن در **ماه گذشته** را Scrape کرده و داده‌های زلزله‌ها را به وسیله کتابخانه‌های **BeautifulSoup** و **Request** جمع‌آوری کرده جدول نهایی را به CSV تبدیل نمایید.

می‌توانید از لینک زیر جداول موجود در HTML این منبع داده مربوط به زلزله‌های این کشور را در دسترس داشته باشید:

[GEOFON Japan Earthquakes Data](#)

فایل‌های نهایی را با نام‌های JAPAN_USGS.csv و JAPAN_GEOFON.csv ذخیره کنید.

منبع سوم وباسکرپینگ از EMSC: از وبسایت مرکز لرزه‌نگاری اروپا-مدیترانه (EMSC)، جدول زلزله‌های ژاپن در **ماه گذشته** را Scrape کرده و داده‌های زلزله‌ها را جمع‌آوری کنید. برای این کار می‌توانید از کتابخانه **Selenium** استفاده کرده و جدول نهایی را به فرمت CSV ذخیره نمایید.

[EMSC Japan Earthquakes Data](#)

منبع چهارم استفاده از دیتاست : با استفاده از دیتاستی که در اختیار شما داده شده عملیات پیش پردازش داده‌ها را انجام داده و داده‌ها را تمیز کنید و به عنوان منبع چهارم استفاده کنید.

[DATASET JAPAN Earthquakes data](#)

فایل‌های نهایی را با نام‌های JAPAN_USGS.csv و JAPAN_GEOFON.csv و JAPAN_EMSC.csv و JAPAN_DATASET.csv ذخیره کنید.

۳. پاک‌سازی، پیش‌پردازش و تحلیل داده‌ها با SQL

در این بخش، پس از وارد کردن داده‌ها به پایگاه داده، تمام عملیات پاک‌سازی، تبدیل داده و تحلیل آماری باید تنها با استفاده از دستورات SQL انجام شود. هدف این بخش آشنایی با قابلیت‌های SQL در مدیریت داده‌های حجیم، انجام محاسبات آماری، گروه‌بندی، فیلتر کردن و آماده‌سازی داده‌ها برای تحلیل است.

تسک‌های بخش SQL

۱. در یک پایگاه داده MySQL یا PostgreSQL، جدولی با نام `earthquakes` ایجاد کنید. این جدول باید شامل ستون‌های `id` (کلید اصلی و خود افزایشی)، `time`، `latitude`، `longitude`، `depth`، `magnitude`، `place` و `source` باشد.

۲. چهار فایل CSV مرحله قبل را در جدول `earthquakes` وارد کنید. برای افزایش کارایی، از پارامترهای `chunksize` و `'if_exists='append'` استفاده نمایید.

۳. ساختار جدول را بررسی کنید و نوع داده هر ستون، تعداد رکوردها و تعداد ستون‌های جدول را گزارش دهید.

۴. مقادیر گمشده (NULL) را در تمامی ستون‌ها شناسایی کنید. سپس با توجه به نوع داده، رکوردهای نامعتبر را حذف کرده یا مقدار مناسبی برای آن‌ها جایگزین نمایید.

۵. داده‌های تکراری را شناسایی کرده و در صورت وجود، آن‌ها را حذف کنید تا هر زلزله تنها یک بار در جدول ثبت شده باشد.

۶. نوع داده ستون‌های `time`، `magnitude` و `depth` را به ترتیب به `DATETIME`، `FLOAT` و `FLOAT` تبدیل کنید.

۷. ستونی جدید با نام **month** ایجاد کرده و شماره ماه وقوع زلزله را از ستون **time** استخراج و در این ستون ذخیره کنید.

۸. ستونی با نام **category** ایجاد کنید که شدت زلزله را بر اساس مقدار بزرگی به سه گروه تقسیم کند. زلزله‌های با بزرگی کمتر از ۴ در گروه «Weak»، زلزله‌های با بزرگی بین ۴ تا ۶ در گروه «Moderate» و زلزله‌های با بزرگی بیشتر از ۶ در گروه «Strong» قرار گیرند.

۹. با استفاده از اطلاعات موجود در ستون **place**، نام منطقه وقوع زلزله را استخراج کرده و در ستونی جدید با نام **region** ذخیره کنید. این عملیات باید برای تمامی رکوردهای جدول انجام شود.

۱۰. تعداد زلزله‌های ثبت‌شده را به تفکیک ماه محاسبه کنید.

۱۱. داده‌ها را بر اساس منطقه (**region**) گروه‌بندی کرده و تحلیل‌های زیر را انجام دهید:

- تعداد زلزله‌های ثبت‌شده در هر منطقه
- میانگین بزرگی زلزله‌ها در هر منطقه
- میانگین عمق زلزله‌ها در هر منطقه
- بیشترین بزرگی ثبت‌شده در هر منطقه
- کمترین و بیشترین عمق ثبت‌شده در هر منطقه

۱۲. داده‌ها را بر اساس **region**، **month** و **category** گروه‌بندی کرده و برای هر گروه، تعداد زلزله‌ها، میانگین بزرگی و میانگین عمق را محاسبه کنید.

۱۳. ده زلزله شدید اخیر را بر اساس زمان وقوع و مقدار بزرگی استخراج کنید.

۱۴. تمامی زلزله‌هایی را که بزرگی آن‌ها بیشتر از ۶ و عمق آن‌ها کمتر از ۵۰ کیلومتر است، نمایش دهید.

۱۵. تعداد زلزله‌های ثبت‌شده را برای هر منبع داده (مانند USGS و GEOFON) محاسبه کنید.

۱۶. میانگین بزرگی زلزله‌ها را به تفکیک منطقه و منبع داده محاسبه کرده و نتایج را به ترتیب بیشترین میانگین مرتب کنید.

۱۷. برای افزایش سرعت اجرای پرس‌وجوها، روی ستون‌های **time**، **region** و **magnitude** ایندکس (Index) ایجاد کنید.

۴. تست‌نویسی و اعتبارسنجی

- برای اطمینان از صحت مراحل انجام شده، تست‌های واحد (Unit Tests) بنویسید. این تست‌ها می‌توانند موارد زیر را پوشش دهند:
 - بررسی صحت دریافت داده (مثلاً تعداد رکوردها یا صحت ساختار جدول خروجی CSV)
 - اطمینان از حذف مقادیر ناقص (چک کنید ستون‌های کلیدی فاقد مقدار خالی باشد)
 - صحت نوع داده‌ها (برای مثال اطمینان از این‌که مقادیر بزرگی عددی هستند)
 - محاسبات آماری (اعلام خطا در صورتی که میانگین یا انحراف معیار به شکل غیرمنتظره‌ای متفاوت باشد)
 - صحت درج داده‌ها در پایگاه داده (مثلاً تعداد ردیف‌ها بعد از INSERT برابر انتظار باشد)
-

۵. نتیجه‌گیری و تحلیل نهایی

ویژگی‌های در ژاپن: با توجه به تحلیل‌های انجام‌شده، تفاوت‌های شاخص بین زلزله‌های مختلف را بررسی کنید مثلاً اکثر این زلزله‌ها دارای چه عمقی هستند و چه شدتی دارند و با توجه به اینکه هرچه عمق این زلزله‌ها کمتر و شدت آن‌ها بیشتر باشد زلزله خطرناک‌تر است زلزله‌های ثبت شده را بر اساس خطرناک بودن رتبه‌بندی کنید

تسک‌ها:

1. بررسی این‌که آیا تمام منابع رخداد‌های کوچک را پوشش می‌دهد؟ چه تفاوتی با یکدیگر دارند؟
2. بررسی اینکه زلزله‌های شدید معمولاً در چه عمقی رخ داده‌اند؟
3. رتبه‌بندی خطرناک‌ترین زلزله‌ها (شدت بالا و عمق کم).
4. مقایسه تعداد زلزله‌های بزرگ در هر منبع.
5. نتیجه‌گیری علمی درباره رفتار زلزله‌ای ژاپن در ماه اخیر. (اختیاری)
6. پیشنهاد برای ترکیب منابع برای بهینه‌سازی کیفیت داده‌ها. (اختیاری)

بخش امتیازی:

از کتابخانه‌های تصویری Python نظیر Matplotlib برای نمایش نتایج استفاده کنید. نمودارهای مورد نیاز عبارتند از:

- هیستوگرام : برای توزیع بزرگی زلزله ها در هر شهر (مثلا تفکیک شده بر اساس هر شهر یا منابع)
- نمودار خطی : روند زمانی شمارش زلزله ها و میانگین بزرگی زلزله ها به ازای هر هفته یا هر روز
- نمودار پراکندگی (Scatter): بزرگی عمق زلزله یا بزرگی در برابر زمان
- نمودار جعبه ای (Boxplot): مقایسه توزیع بزرگی با عمق زلزله ها
- هیت مپ (Heatmap): نقشه حرارتی توزیع جغرافیایی زلزله ها با استفاده از طول و عرض جغرافیایی زلزله های رخ داده و همچنین نقشه حرارتی زلزله های رخ داده با استفاده از فاصله کانونی زلزله تا توکیو

موفق باشید ==))